

Генеративные модели

Лекция 3: Модели со скрытыми
переменными

Идея нормализующих потоков


Особенность потоков – наличие двух направлений:

- **Нормализующее направление (для обучения)** $x \rightarrow z$:

Берём реальный объект x и с помощью нормализующей функции f превращаем его в простой z

- **Генеративное направление** $z \rightarrow x$:

Берём простой объект z и с помощью генеративной функции $g = f^{-1}$ создаём объект x



Теорема о замене переменных

Наша цель – найти распределение $p(\mathbf{x})$

Связать неизвестную плотность $p(\mathbf{x})$ с известной плотностью простого распределения $p(\mathbf{z})$ нам позволяет **формула замены переменных**:

$$p(\mathbf{x}) = p(\mathbf{z}) |\det(J_f)| = p(\mathbf{z}) \left| \det \left(\frac{\partial \mathbf{z}}{\partial \mathbf{x}} \right) \right| = p(\mathbf{f}(\mathbf{x})) \left| \det \left(\frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} \right) \right|$$

Здесь $J_f(\mathbf{x})$ – матрица Якоби:


$$J_f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_D} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_D}{\partial x_1} & \dots & \frac{\partial f_D}{\partial x_D} \end{pmatrix}$$

Композиция преобразований

- Одной функции f недостаточно, чтобы из $\mathcal{N}(0,1)$ получить сложное распределение наших данных
- Потoki используют последовательность из K простых и обратимых преобразований:

$$\mathbf{x} = \mathbf{z}_0 \xrightarrow{f_1} \mathbf{z}_1 \xrightarrow{f_2} \dots \xrightarrow{f_K} \mathbf{z}_K$$


- Во время обучения мы используем нормализующее направление $\mathbf{x} \rightarrow \mathbf{z}$:



Композиция преобразований

- Генеративное направление $\mathbf{z} \rightarrow \mathbf{x}$ используется для создания новых объектов:

$$\mathbf{z}_0 \xrightarrow{g_1} \mathbf{z}_1 \xrightarrow{g_2} \dots \xrightarrow{g_K} \mathbf{z}_K = \mathbf{x}$$



Композиция преобразований

Нужно найти определитель якобиана всей композиции

Два математических факта:

- Матрица Якоби для композиций функций равна их произведению:

$$\frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \frac{\partial \mathbf{f}_K}{\partial \mathbf{z}_{K-1}} \cdot \frac{\partial \mathbf{f}_{K-1}}{\partial \mathbf{z}_{K-2}} \cdot \dots \cdot \frac{\partial \mathbf{f}_1}{\partial \mathbf{z}_0}$$

- Определитель произведения матриц равен произведению определителей:

$$\det(\mathbf{J}_f) = \det(\mathbf{J}_{f_K}) \cdot \det(\mathbf{J}_{f_{K-1}}) \cdot \dots \cdot \det(\mathbf{J}_{f_1})$$

Будем считать определители для каждого шага \mathbf{f}_k и перемножать их:

$$\det\left(\frac{\partial \mathbf{f}}{\partial \mathbf{x}}\right) = \prod_{k=1}^K \det\left(\frac{\partial \mathbf{f}_k}{\partial \mathbf{z}_{k-1}}\right)$$

Обучение нормализующих потоков

Чтобы сделать эту композицию обучаемой, представим f_k как нейросеть с параметрами θ

Плотность, которую моделирует наша модель:

$$p_{\theta}(\mathbf{x}) = p(\mathbf{f}_{\theta}(\mathbf{x})) \left| \det \left(\frac{\partial \mathbf{f}_{\theta}}{\partial \mathbf{x}} \right) \right| = p(\mathbf{z}_K) \left| \prod_{k=1}^K \det \left(\frac{\partial \mathbf{f}_{k,\theta}}{\partial \mathbf{z}_{k-1}} \right) \right|$$

\mathbf{z}_K — финальный вектор в латентном пространстве

Максимизируем правдоподобие:

$$\log p_{\theta}(\mathbf{x}) = \log p(\mathbf{z}_K) + \sum_{k=1}^K \log \left| \det \left(\frac{\partial \mathbf{f}_{k,\theta}}{\partial \mathbf{z}_{k-1}} \right) \right|$$

- $\log p(\mathbf{z}_K)$ отвечает за то, чтобы выход потока соответствовал базовому распределению
- $\sum_{k=1}^K \log \left| \det \left(\frac{\partial \mathbf{f}_{k,\theta}}{\partial \mathbf{z}_{k-1}} \right) \right|$ отслеживает суммарное изменение объема после всех преобразований

План

- Модели со скрытыми переменными

- EM алгоритм

- Вариационный вывод

Модели со скрытыми переменными

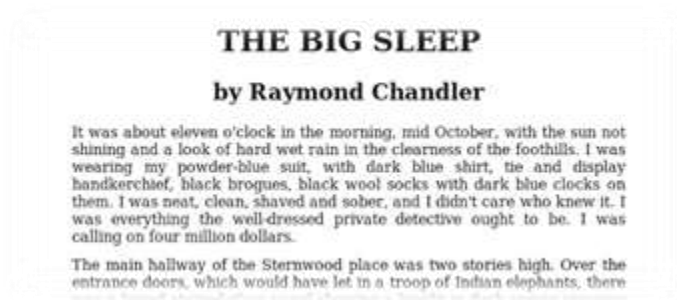
Проблема высокой размерности

Ищем θ , которые максимизируют правдоподобие:

$$\theta^* = \arg \max_{\theta} \sum_{i=1}^n \log p_{\theta}(\mathbf{x}_i)$$

Объекты в реальном мире – многомерные случайные величины

Прямое моделирование $p_{\theta}(\mathbf{x}) = p_{\theta}(x_1, x_2, \dots, x_D)$ – сложная задача из-за проклятия размерности



Модели со скрытыми переменными

Предположим, что помимо наблюдаемой переменной \mathbf{x} в нашей задаче есть некоторая скрытая переменная \mathbf{z} , которая влияет на \mathbf{x}

Мы не можем измерить ее напрямую, но знаем, что она есть

Мы можем записать совместную плотность и разложить ее на условную и априорную:

$$p(\mathbf{x}, \mathbf{z} | \boldsymbol{\theta}) = p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta}) \cdot p(\mathbf{z} | \boldsymbol{\theta})$$

$p(\mathbf{z} | \boldsymbol{\theta})$ – априорное распределение на скрытых переменных

$p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta})$ – условное распределение наблюдаемых данных

Проинтегрируем по всем \mathbf{z} , чтобы найти правдоподобие:

$$p(\mathbf{x} | \boldsymbol{\theta}) = \int p(\mathbf{x}, \mathbf{z} | \boldsymbol{\theta}) d\mathbf{z} = \int p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta}) \cdot p(\mathbf{z} | \boldsymbol{\theta}) d\mathbf{z}$$

Модели со скрытыми переменными

Наша цель – по-прежнему максимизация правдоподобия:

$$\boldsymbol{\theta}^* = \arg \max_{\boldsymbol{\theta}} \sum_{i=1}^n \log p_{\boldsymbol{\theta}}(\mathbf{x}_i) \quad \rightarrow \quad \boldsymbol{\theta}^* = \arg \max_{\boldsymbol{\theta}} \sum_{i=1}^n \log \int p(\mathbf{x}_i | \mathbf{z}_i, \boldsymbol{\theta}) \cdot p(\mathbf{z}_i | \boldsymbol{\theta}) d\mathbf{z}_i$$

Мы заменили одно сложное распределение $p(\mathbf{x}|\boldsymbol{\theta})$ на интеграл от двух более простых:

$$\log p(\mathbf{x}|\boldsymbol{\theta}) = \log \int p(\mathbf{x}|\mathbf{z}, \boldsymbol{\theta}) \cdot p(\mathbf{z}|\boldsymbol{\theta}) d\mathbf{z} \quad \rightarrow \quad \max_{\boldsymbol{\theta}}$$


Выбирая подходящие распределения для $p(\mathbf{x}|\mathbf{z}, \boldsymbol{\theta})$ и $p(\mathbf{z}|\boldsymbol{\theta})$, мы можем либо получить аналитическое решение для $\boldsymbol{\theta}^*$, либо использовать методы оптимизации

Gaussian Mixture Models

- Реальные данные редко описываются одним простым распределением
- Мы можем представить сложное распределение как взвешенную сумму (смесь) более простых распределений

Самый популярный представитель – *модели гауссовских смесей (Gaussian Mixture Models)*

- Сначала случайно берём одну из K компонент
- Затем семплируем вектор \mathbf{x} из выбранного распределения $\mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$
- Номер компоненты, из которой пришел вектор, является скрытой переменной \mathbf{z} (мы её не наблюдаем)



Gaussian Mixture Models

Скрытая переменная \mathbf{z} — это бинарный вектор $\mathbf{z} = \{0,1\}^K$, где \mathbf{z}_k означает принадлежность к k -ой компоненте

Априорная вероятность $p(\mathbf{z}|\boldsymbol{\theta})$ задается весами смеси π_k , при этом:

$$\sum_{k=1}^K \pi_k = 1$$

Если точка пришла из k -ой компоненты, то ее вероятность описывается гауссианой:

$$p(\mathbf{x}|\mathbf{z}_k = 1, \boldsymbol{\theta}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$


Итоговое правдоподобие:

$$p(\mathbf{x}|\boldsymbol{\theta}) = \sum_{k=1}^K p(\mathbf{z}_k = 1|\boldsymbol{\theta}) \cdot p(\mathbf{x}|\mathbf{z}_k = 1, \boldsymbol{\theta}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

MLE для моделей со скрытыми переменными

Нужно вычислить сложный интеграл:

$$\sum_{i=1}^n \log p(\mathbf{x}_i | \boldsymbol{\theta}) = \sum_{i=1}^n \log \int p(\mathbf{x}_i | \mathbf{z}_i, \boldsymbol{\theta}) \cdot p(\mathbf{z}_i) d\mathbf{z}_i$$




Попробуем оценить этот интеграл методом Монте-Карло:

$$p(\mathbf{x} | \boldsymbol{\theta}) = \int p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta}) \cdot p(\mathbf{z}) d\mathbf{z} = \mathbb{E}_{p(\mathbf{z})}[p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta})] \approx \frac{1}{K} \sum_{k=1}^K p(\mathbf{x} | \mathbf{z}_k, \boldsymbol{\theta})$$

MLE для моделей со скрытыми переменными

- Большинство сэмплов \mathbf{z}_k попадут в «бесполезные» области и декодер сгенерирует шум



Наше априорное распределение $p(\mathbf{z})$ ничего не знает об изображениях \mathbf{x}

В многомерном пространстве объем «пустого» пространства огромен по сравнению с объемом полезной области

Чтобы получить надежную оценку интеграла, нам понадобится экспоненциально большое число сэмплов K

ЕМ алгоритм

Модели со скрытыми переменными

В моделях со скрытыми переменными наша цель – максимизировать логарифм правдоподобия $\log p(X|\theta)$

Из-за наличия скрытых переменных правдоподобие выражается через интеграл (сумму)

$$p(X|\theta) = \int p(X, Z|\theta) dZ$$

Итоговая функция, которую мы максимизируем, содержит интеграл внутри логарифма:

$$\log p(X|\theta) = \log \int p(X, Z|\theta) dZ \rightarrow \max_{\theta}$$

Наивная оценка не работает:

Попытка оценить эти интегралы методом Монте-Карло проваливается из-за проклятия размерности

Формула Байеса

Введем понятия:

X — наши реальные, неполные данные

$\{X, Z\}$ — полные данные

Мы не знаем точные значения Z , но можем вычислить апостериорное распределение:

$$p(Z|X, \theta) = \frac{p(X|Z, \theta) \cdot p(Z|\theta)}{p(X|\theta)}$$

- $p(Z|X, \theta)$ — **апостериорное распределение**, вероятность того, что скрытые переменные приняли значение Z , после того как мы увидели данные X
- $p(X|Z, \theta)$ — **правдоподобие**, вероятность увидеть данные X , если скрытые переменные равны Z
- $p(Z|\theta)$ — **априорное распределение**, насколько вероятны значения Z до наблюдений
- $p(X|\theta)$ — **обоснованность (evidence)** вероятность увидеть данные X

ЕМ алгоритм

- Пусть у нас есть уже есть некоторая оценка параметров θ_{old}
- Будем итеративно выполнять 2 шага

E-шаг (Expectation):

Используя текущие значения θ_{old} , находим апостериорное распределение $p(\mathbf{Z}|\mathbf{X}, \theta_{old})$ и вычисляем матожидание логарифма правдоподобия для полных данных $\{\mathbf{X}, \mathbf{Z}\}$:

$$Q(\theta, \theta_{old}) = \int p(\mathbf{Z}|\mathbf{X}, \theta_{old}) \cdot \log p(\mathbf{X}, \mathbf{Z}|\theta) d\mathbf{Z}$$

M-шаг (Maximization):

Обновляем оценку параметров θ , новые значения выбираются таким образом, чтобы максимизировать $Q(\theta, \theta_{old})$:

$$\theta_{new} = \arg \max_{\theta} Q(\theta, \theta_{old})$$

ЕМ алгоритм

Чтобы вычислить знаменатель $p(\mathbf{X}|\boldsymbol{\theta})$ в формуле для апостериорного распределения, нам нужно взять интеграл:

$$p(\mathbf{X}|\boldsymbol{\theta}) = \int p(\mathbf{X}, \mathbf{Z}|\boldsymbol{\theta}) d\mathbf{Z}$$

В случае **GMM** мы можем получить аналитическое решение:

$$p(\mathbf{X}|\boldsymbol{\theta}) = \sum_{k=1}^K p(\mathbf{Z} = k|\boldsymbol{\theta}) \cdot p(\mathbf{X}|\mathbf{Z} = k, \boldsymbol{\theta})$$

ЕМ алгоритм

ЕМ алгоритм прекрасен, но для более сложных моделей вычислить истинное апостериорное распределение $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}_{old})$ на *E-stage* аналитически невозможно

- Будем аппроксимировать распределение $p(\mathbf{Z}|\mathbf{X}, \boldsymbol{\theta}_{old})$
- В этом и состоит идея *вариационного вывода* (*Variational Inference*)

Вариационный вывод

Вариационный вывод

Наша цель — оценить $\log p(\mathbf{x}|\boldsymbol{\theta})$:

$$\log p(\mathbf{x}|\boldsymbol{\theta}) = \log \int p(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) d\mathbf{z}$$

Введем вспомогательное распределение $q(\mathbf{z})$ — произвольную плотность над скрытыми переменными \mathbf{z}

Идея:

Мы не знаем $\log p(\mathbf{x}|\boldsymbol{\theta})$, но можем попытаться построить для него некую **нижнюю границу** (*lower bound*), которую будем оптимизировать

Вывод *ELBO* (1)

Умножим и разделим выражение для $\log p(\mathbf{x}|\boldsymbol{\theta})$ на $q(\mathbf{z})$:

$$\log p(\mathbf{x}|\boldsymbol{\theta}) = \log \int p(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) d\mathbf{z} = \log \int \frac{q(\mathbf{z})}{q(\mathbf{z})} p(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta}) d\mathbf{z} =$$

$$\log \mathbb{E}_q \left[\frac{p(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta})}{q(\mathbf{z})} \right] \geq \mathbb{E}_q \log \frac{p(\mathbf{x}, \mathbf{z}|\boldsymbol{\theta})}{q(\mathbf{z})} = \mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$$

Неравенство Йенсена:

$$\log \mathbb{E}[X] \geq \mathbb{E}[\log X]$$


Мы получили **вариационную нижнюю оценку** (*Evidence Lower Bound, ELBO*), которая утверждает, что для любого $q(\mathbf{z})$:

$$\log p(\mathbf{x}|\boldsymbol{\theta}) \geq \mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$$

Вывод *ELBO* (1)

$q(\mathbf{z})$ будем называть *вариационным распределением*

Насколько далеко наша нижняя граница $\mathcal{L}_{q,\theta}(\mathbf{x})$ находится от истинного значения $\log p(\mathbf{x}|\theta)$?



Вывод *ELBO* (2)

Перепишем выражение для ***ELBO***:

$$\mathcal{L}_{q,\theta}(\mathbf{x}) = \int q(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z} | \boldsymbol{\theta})}{q(\mathbf{z})} d\mathbf{z} = \int q(\mathbf{z}) \log \frac{p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta}) \cdot p(\mathbf{x} | \boldsymbol{\theta})}{q(\mathbf{z})} d\mathbf{z} =$$


$$\int q(\mathbf{z}) \log p(\mathbf{x} | \boldsymbol{\theta}) d\mathbf{z} + \int q(\mathbf{z}) \log \frac{p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta})}{q(\mathbf{z})} d\mathbf{z} = \log p(\mathbf{x} | \boldsymbol{\theta}) \int q(\mathbf{z}) d\mathbf{z} + \int q(\mathbf{z}) \log \frac{p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta})}{q(\mathbf{z})} d\mathbf{z} =$$

$$\log p(\mathbf{x} | \boldsymbol{\theta}) + \int q(\mathbf{z}) \log \frac{p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta})}{q(\mathbf{z})} d\mathbf{z} = \log p(\mathbf{x} | \boldsymbol{\theta}) + KL(q(\mathbf{z}) || p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta}))$$

Вывод *ELBO* (2)

Зазор между $\log p(\mathbf{x}|\boldsymbol{\theta})$ и $\mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$ равен KL -дивергенции между вариационным распределением $q(\mathbf{z})$ и истинным апостериорным распределением $p(\mathbf{z}|\mathbf{x}, \boldsymbol{\theta})$:

$$\log p(\mathbf{x}|\boldsymbol{\theta}) - \mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x}) = KL(q(\mathbf{z})||p(\mathbf{z}|\mathbf{x}, \boldsymbol{\theta}))$$



Вывод *ELBO* (2)

Получим ещё одно выражение для ***ELBO***, используя разложение $p(\mathbf{x}, \mathbf{z} | \boldsymbol{\theta}) = p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta}) \cdot p(\mathbf{z})$

$$\mathcal{L}_{q, \boldsymbol{\theta}}(\mathbf{x}) = \int q(\mathbf{z}) \log \frac{p(\mathbf{x}, \mathbf{z} | \boldsymbol{\theta})}{q(\mathbf{z})} d\mathbf{z} = \int q(\mathbf{z}) \log p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta}) d\mathbf{z} + \int q(\mathbf{z}) \log \frac{p(\mathbf{z})}{q(\mathbf{z})} d\mathbf{z}$$

$$\underbrace{\mathbb{E}_q[\log p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta})]}_{\text{Reconstruction loss}} - \underbrace{KL(q(\mathbf{z}) || p(\mathbf{z}))}_{\text{Regularization loss}}$$

Итоговое правдоподобие:

$$\begin{aligned} \log p(\mathbf{x} | \boldsymbol{\theta}) &= \mathcal{L}_{q, \boldsymbol{\theta}}(\mathbf{x}) + KL(q(\mathbf{z}) || p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta})) = \\ &\mathbb{E}_q[\log p(\mathbf{x} | \mathbf{z}, \boldsymbol{\theta})] - KL(q(\mathbf{z}) || p(\mathbf{z})) + KL(q(\mathbf{z}) || p(\mathbf{z} | \mathbf{x}, \boldsymbol{\theta})) \end{aligned}$$

Выводы

Вместо прямой максимизации правдоподобия $\log p(\mathbf{x}|\boldsymbol{\theta})$ будем максимизировать его нижнюю границу $\mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$ по параметрам вариационного распределения q и параметрам модели $\boldsymbol{\theta}$:

$$\max_{q,\boldsymbol{\theta}} \mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$$

Максимизируя $\mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$, мы одновременно стараемся сделать 2 вещи:

1. Увеличить правдоподобие наблюдаемых данных
2. Уменьшить зазор $KL(q(\mathbf{z})||p(\mathbf{z}|\mathbf{x},\boldsymbol{\theta}))$, аппроксимируя $p(\mathbf{z}|\mathbf{x},\boldsymbol{\theta})$ с помощью $q(\mathbf{z})$

ЕМ алгоритм

Мы получили следующее выражение:


$$\log p(\mathbf{x}|\boldsymbol{\theta}) = \mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x}) + KL(q(\mathbf{z})||p(\mathbf{z}|\mathbf{x}, \boldsymbol{\theta}))$$

- ЕМ алгоритм можно интерпретировать как метод координатного подъёма (*coordinate ascent*) по *ELBO*
- Он итеративно оптимизирует $\mathcal{L}_{q,\boldsymbol{\theta}}(\mathbf{x})$, поочерёдно фиксируя либо параметры вариационного распределения $q(\mathbf{z})$, либо параметры модели $\boldsymbol{\theta}$


Е – шаг

E-шаг:

- Фиксируем θ_{old} и ищем оптимальное $q(\mathbf{z})$, которое максимизирует $\mathcal{L}_{q, \theta_{old}}(\mathbf{x})$




- $\log p(\mathbf{x}|\theta)$ не зависит от $q(\mathbf{z})$, поэтому $\mathcal{L}_{q, \theta_{old}}(\mathbf{x})$ максимальна, когда $KL(q(\mathbf{z})||p(\mathbf{z}|\mathbf{x}, \theta)) = 0$
- Наилучший выбор для $q(\mathbf{z})$ – это апостериорное распределение $p(\mathbf{z}|\mathbf{x}, \theta)$




M – шаг

M -шаг:

- Фиксируем найденное распределение $q(\mathbf{z})$ и пытаемся увеличить $\mathcal{L}_{q, \theta_{old}}(\mathbf{x})$




- Увеличение нижней границы гарантирует $\mathcal{L}_{q, \theta}(\mathbf{x})$ увеличение $\log p(\mathbf{x}|\theta)$ (если мы не в максимуме)
- Распределение $q(\mathbf{z})$ было определено на основе старых параметров θ_{old} , поэтому оно не равно апостериорному распределению $p(\mathbf{z}|\mathbf{x}, \theta_{new})$



ЕМ – алгоритм

- Работу ЕМ-алгоритма можно рассмотреть в пространстве параметров
- На Е-шаге мы строим нижнюю границу $\mathcal{L}_{q,\theta_{old}}(\mathbf{x})$, которая касается $\log p(\mathbf{x}|\theta)$ в точке θ_{old}
- На М-шаге ищем максимум этой нижней границы (точка θ_{new}), что приводит к большему значению $\log p(\mathbf{x}|\theta_{new})$



Спасибо за внимание!